Questão 07 — Titanic e Apriori

Objetivo: encontrar perfis de passageiros associados à sobrevivência, usando itens presentes e ausentes.

1) Preparação da base

Usei titanic.csv do repositório seaborn-data: 891 passageiros, 342 sobreviventes e 549 não sobreviventes. Nenhuma linha foi excluída.

Idade: preenchi 177 ausências com a mediana do grupo sexo × classe. A mediana global fica como reserva. A sobrevivência não entra nessa imputação.

Embarque: preenchi os 2 ausentes com S, a moda. A tarifa não tinha ausências; o código prevê a mediana se necessário.

Atributos escolhidos

Classe, sexo, idade, tarifa, porto de embarque e número de familiares a bordo. O alvo é Sobreviveu=Sim/Não.

Família = sibsp + parch: irmãos/cônjuge + pais/filhos; o próprio passageiro não entra nessa soma.

Excluí deck, com 688 ausências. Removi class, embark_town, alone, who e adult_male por redundância ou derivação. alive replica o alvo e causaria vazamento.

Esta versão já não tem nomes nem identificadores. Se existissem, também seriam removidos.

Material: o Apriori.ipynb da disciplina não foi fornecido; usei uma implementação própria e comentada do Apriori.

Discretização e itens de ausência

1b) Faixas usadas antes de minerar

Idade: [0,18), [18,23), [23,41) e [41,+infinito). São as faixas 0–17, 18–22, 23–40 e 41+; idades fracionárias entram sem arredondamento.

A separação distingue menores de idade, jovens, adultos e adultos mais velhos, seguindo a sugestão do enunciado.

Tarifa: [0,10), [10,30), [30,100) e [100,+infinito), em libras. São faixas amplas de preço; não são classes sociais nem quantis.

Família: 0 (sozinho), 1–3 e 4+. Diferenciam ausência de parentes, grupos pequenos e grupos maiores.

As fronteiras são escolhas interpretáveis, não valores otimizados pelo desfecho. Outras faixas podem mudar as regras.

1c e 2) Codificação binária

Cada atributo=valor vira uma coluna booleana: Classe=1a, Idade=18-22 etc.

Para cada coluna x de perfil, criei o complemento NÃO x = 1 - x.

Exemplo: um passageiro da 2a classe tem Classe=2a igual a 1 e NÃO Classe=1a igual a 1.

NÃO Idade=18-22 reúne as outras três faixas. Ausência da característica não significa valor desconhecido: os dados já foram tratados.

Total: 19 itens de perfil + 19 negações + 2 itens de sobrevivência = 40 colunas, em 891 transações.

Não dupliquei negações do alvo: NÃO Sobreviveu=Sim seria o mesmo que Sobreviveu=Não.

Execução e escolha dos parâmetros

3a) O Apriori conta itens, combina os frequentes e poda candidatos com subconjuntos infrequentes. Usei itemsets de tamanho até 3 para obter antecedentes com até 2 itens.

Para cada itemset frequente, gerei todas as partições A → B, respeitando suporte e confiança mínimos.

3b) Comparação das configurações

Sup.	Conf.	Itemsets	Todas	Filtradas
5%	70%	6188	9475	131
10%	70%	4344	7690	108
10%	80%	4344	5055	36
15%	80%	3144	4247	31
10%	90%	4344	2691	2

"Todas" inclui regras entre quaisquer itens. "Filtradas" mantém só sobrevivência no consequente, sem alvo no antecedente, lift > 1 e atributos diferentes no antecedente.

Também reuni antecedentes que selecionam os mesmos passageiros, preferindo menos negações. Isso evita repetir Homem e NÃO Mulher, por exemplo. É equivalência na amostra.

Escolhi suporte 10% e confiança 80%: pelo menos 90 passageiros satisfazem a regra completa, com 36 regras interpretáveis. A 90% de confiança restam só 2; suporte 15% perde perfis menores.

3c) Métricas

sup(A → B) = n(A e B) / 891

conf(A → B) = n(A e B) / n(A)

lift(A → B) = conf(A → B) / P(B)

Bases: P(Sim)=38,38%; P(Não)=61,62%. Lift > 1 indica associação positiva com o consequente.

4) Regras de sobrevivência

As cinco regras com Sobreviveu=Sim, em ordem decrescente de lift. "n" conta quem satisfaz antecedente e consequente; "A" conta só o antecedente.

S1. Classe 1a + Mulher → Sim

n/A = 91/94 | sup 10,21% | conf 96,81%

lift = 2,522

S2. Mulher + NÃO Classe 3a → Sim

n/A = 161/170 | sup 18,07% | conf 94,71%

lift = 2,467

S3. Mulher + NÃO Porto S → Sim

n/A = 91/109 | sup 10,21% | conf 83,49%

lift = 2,175

S4. Mulher + Idade 23-40 → Sim

n/A = 104/128 | sup 11,67% | conf 81,25%

lift = 2,117

S5. Mulher + Família 1-3 → Sim

n/A = 125/155 | sup 14,03% | conf 80,65%

lift = 2,101

Interpretações

S1: 91 das 94 mulheres da 1a classe sobreviveram. A proporção é 2,52 vezes a taxa de sobrevivência da base inteira.

S2 (ausência): mulheres NÃO da 3a classe são as da 1a ou 2a. Sobreviveram 161 de 170; o grupo reúne duas classes, sem atribuir uma causa à classe.

S3 (ausência): entre mulheres que NÃO embarcaram em Southampton, 91 de 109 sobreviveram. O grupo reúne C e Q; porto pode refletir outros fatores, como classe e tarifa.

S4 e S5: mulheres de 23–40 anos e mulheres com 1–3 familiares também apresentam sobrevivência acima de 80%. As regras se sobrepõem; seus suportes não devem ser somados.

4) Regras de não sobrevivência

As cinco primeiras regras abaixo são as de maior lift para Sobreviveu=Não.

N1. Homem + Tarifa <10 → Não

n/A = 243/272 | sup 27,27% | conf 89,34%

lift = 1,450

N2. Idade 23–40 + Tarifa <10 → Não

n/A = 167/191 | sup 18,74% | conf 87,43%

lift = 1,419

N3. Classe 3a + Homem → Não

n/A = 300/347 | sup 33,67% | conf 86,46%

lift = 1,403

N4. Homem + NÃO Classe 1a → Não

n/A = 391/455 | sup 43,88% | conf 85,93%

lift = 1,395

N5. Tarifa <10 + NÃO Idade 18–22 → Não

n/A = 205/240 | sup 23,01% | conf 85,42%

lift = 1,386

Interpretações

N1: 243 de 272 homens com tarifa inferior a 10 não sobreviveram (89,34%). O lift 1,450 compara essa taxa aos 61,62% de não sobrevivência da base.

N3: na 3a classe, 300 de 347 homens não sobreviveram. A confiança de 86,46% mostra um perfil de alta mortalidade nesta amostra.

N5 (ausência): tarifa <10 e NÃO idade 18–22 agrupa menores de 18 e passageiros de 23 anos ou mais. Houve 205 mortes entre 240 passageiros desse perfil.

As regras de morte têm lift menor que as de sobrevivência porque a taxa de morte de referência já é maior. Confiança alta, sozinha, não basta para avaliar uma regra.

Todas as regras selecionadas (1–18)

Ordem global por lift. S = Sobreviveu Sim; N = Sobreviveu Não. Valores: suporte (%) / confiança (%) / lift.

01. Classe 1a + Mulher → S
    10,21% / 96,81% / 2,522
02. Mulher + NÃO Classe 3a → S
    18,07% / 94,71% / 2,467
03. Mulher + NÃO Porto S → S
    10,21% / 83,49% / 2,175
04. Mulher + Idade 23-40 → S
    11,67% / 81,25% / 2,117
05. Mulher + Família 1-3 → S
    14,03% / 80,65% / 2,101
06. Homem + Tarifa <10 → N
    27,27% / 89,34% / 1,450
07. Idade 23-40 + Tarifa <10 → N
    18,74% / 87,43% / 1,419
08. Classe 3a + Homem → N
    33,67% / 86,46% / 1,403
09. Homem + NÃO Classe 1a → N
    43,88% / 85,93% / 1,395
10. Tarifa <10 + NÃO Idade 18-22 → N
    23,01% / 85,42% / 1,386
11. Homem + NÃO Família 1-3 → N
    42,09% / 85,23% / 1,383
12. Tarifa <10 + Porto S → N
    23,34% / 84,90% / 1,378
13. Homem + Família Sozinho → N
    38,95% / 84,43% / 1,370
14. Homem + NÃO Tarifa 30-<100 → N
    44,56% / 84,29% / 1,368
15. Classe 2a + Homem → N
    10,21% / 84,26% / 1,367
16. Tarifa <10 + NÃO Porto Q → N
    26,49% / 83,69% / 1,358
17. Homem + NÃO Idade 0-17 → N
    48,60% / 83,43% / 1,354
18. Homem + NÃO Porto C → N
    45,12% / 83,40% / 1,354

Todas as regras selecionadas (19–36)

Ordem global por lift. S = Sobreviveu Sim; N = Sobreviveu Não. Valores: suporte (%) / confiança (%) / lift.

19. Homem + Porto S → N
    40,85% / 82,54% / 1,340
20. Homem + Idade 23-40 → N
    31,65% / 82,46% / 1,338
21. Homem + NÃO Tarifa 10-<30 → N
    36,59% / 82,12% / 1,333
22. Classe 3a + Idade 23-40 → N
    23,01% / 82,00% / 1,331
23. Homem + NÃO Tarifa 100+ → N
    51,18% / 81,72% / 1,326
24. Tarifa <10 + NÃO Idade 0-17 → N
    28,84% / 81,33% / 1,320
25. Homem → N
    52,53% / 81,11% / 1,316
26. Classe 3a + Porto S → N
    32,10% / 81,02% / 1,315
27. Homem + NÃO Idade 41+ → N
    43,32% / 80,92% / 1,313
28. Classe 3a + NÃO Família 1-3 → N
    34,23% / 80,69% / 1,310
29. Tarifa <10 + NÃO Porto C → N
    27,05% / 80,60% / 1,308
30. Tarifa <10 + Família Sozinho → N
    28,06% / 80,39% / 1,305
31. Homem + NÃO Classe 2a → N
    42,31% / 80,38% / 1,305
32. Tarifa <10 + NÃO Família 4+ → N
    30,19% / 80,30% / 1,303
33. Homem + NÃO Família 4+ → N
    49,38% / 80,29% / 1,303
34. Homem + NÃO Porto Q → N
    48,26% / 80,22% / 1,302
35. Tarifa <10 + NÃO Família 1-3 → N
    28,06% / 80,13% / 1,300
36. Tarifa <10 → N
    30,19% / 80,06% / 1,299

Conclusões e reprodução

Nesta amostra, sexo e classe aparecem em perfis associados à sobrevivência. Mulheres da 1a ou 2a classe têm alta sobrevivência; homens com tarifas baixas e da 3a classe têm alta não sobrevivência.

Os itens de ausência ampliam a leitura dos grupos: NÃO 3a classe reúne 1a e 2a, enquanto NÃO 18–22 reúne três faixas etárias. O significado de cada complemento deve ficar explícito.

Limitações da análise

Associação não demonstra causalidade. Não houve teste de significância, correção por múltiplas comparações ou validação em outra amostra. Regras podem compartilhar os mesmos passageiros.

A imputação pode deslocar idades entre faixas. As escolhas de discretização, suporte e limite de tamanho afetam o resultado; a mineração é descritiva, não um modelo validado de previsão.

Os filtros reduzem regras triviais e duplicadas, mas não eliminam toda redundância. As 36 regras estão integralmente nas páginas 6–7 e no arquivo CSV.

Notebook comentado e executado

Abrir Lista5_resolvida.ipynb (clique aqui)

O link é relativo: mantenha o notebook na mesma pasta do PDF e abra em um leitor que aceite links locais. O navegador pode bloquear esse tipo de link.

Para entregar por link público, publique o notebook no Colab ou GitHub e substitua este link. O arquivo já contém as saídas, comentários e uma cópia incorporada da base.

Fonte dos dados (link)

github.com/mwaskom/seaborn-data

Arquivo: titanic.csv • acesso em 17/10/2026

Conferência: as 36 regras foram recontadas diretamente na matriz binária; suporte, confiança e lift coincidiram com as saídas do Apriori.